ECOLE NATIONALE POLYTECHNIQUE GENIE INDUSTRIEL DS & AI

COMPTE RENDU DU TP2.

Codage de Huffman et arithmétique-Compression et décompression TINFO.

Fait par:

OUCHENE SOUHIL

souhil.ouchene@g.enp.edu.dz

1 DS & IA

Objectif du TP

Compression et décompression d'une séquence numérique, en utilisant les algorithmes de Huffman et Arithmétique. Comparaison de l'efficacité des deux algorithmes en matière de compression.

Partie 1

Considérant l'alphabet de la source Alpha= {1, 2, 3} et la séquence à compresser : Seq=3313333323.

1. Utilisation des fonctions huffmandict & huffmanenco :

> CODE MATLAB

```
% initialisation:
Alpha= [1 2 3];
Seq=[3 3 1 3 3 3 3 3 2 3];
%compression avec huffman
nb 1=0;
nb_2=0;
nb^{-}3=0;
%calcul de probabilites:
prob occ=[0 0 0];
for i=1:length(Seq)
    if(Seq(i) == 1)
        nb 1=nb 1+1;
    elseif (Seq(i) == 2)
        nb 2=nb 2+1;
    else
        nb 3=nb 3+1;
    end
end
%creation du dictionnaire :
prob occ=1/10 * [nb 1 nb 2 nb 3];
dict=huffmandict(Alpha, prob occ);
dict;
%codage du messsage:
enco huff=huffmanenco(Seq, dict);
enco huff;
```

Résultats

Le dictionnaire est comme suit :

1	[1,1]
2	[1,0]
3	0

Le codage du message sera alors comme suit :

enco_huff =

2. Utilisation de la fonction **huffmandeco** pour la décompression :

> CODE MATLAB

%decodage:
decode_huff=huffmandeco(enco_huff, dict);

> Résultats

decode_huff = 3 3 3 3 3 2 3

Ceci est identique au message compressé avant et après décompression.

3. Comparaison:

On sait qu'on a 1 octet (8 bits) pour chaque symbole du code original, alors :

CODE MATLAB

```
%comparaison
diff=length(Seq) *8-length(enco_huff);
diff;
if (diff>0)
        display("le compresseur de huffman nous a permet de gagner de l'espace")
end
```

Résultats

On voit bien que la différence est de 68 bits, cad la compression de **huffman** nous a permet de gagner un espace de 68 bits .

```
diff = "le compresseur de huffman nous a permet de gagner de l'espace"
```

4. Utilisation de la fonction arithenco:

> CODE MATLAB

```
%compression avec arithmetique:
counts = [1 1 8];
enco_arth=arithenco(Seq, counts);
enco_arth;
```

Résultats

On aura:

enco_arth =

0 1 1 0 0 0 1 1 0 0 0 0

5. Décompression en utilisant la fonction arithdeco:

> CODE MATLAB

```
len=length(Seq);
decode_arth=arithdeco(enco_arth, counts, len);
decode_arth;
```

Résultats

On aura alors:

0

Ceci est identique au message compressé avant et après décompression.

6. Comparaison :

> CODE MATLAB

```
%comparaison 2
diff_1=length(Seq)*8-length(enco_arth);
diff_1;
if (diff_1>0)
        display("le compresseur arithmetique nous a permet de gagner de l'espace")
end
```

> Résultats

On voit bien que la différence est de 65 bits en mémoire, cad la compression **arithmétique** nous a permet de gagner un espace de 65 bits.

```
"le compresseur arithmetique nous a permet de gagner de l'espace"

65
```

7. Comparaison entre la compression de **Huffman** et la compression **arithmétique** :

Comme on ne peut pas calculer l'efficacité de ces 2 codages (on ne peut pas calculer la longueur moyenne), on va comparer ces 2 méthodes selon le nombre de bits dans chaque message codé cad calculer la différence entre la taille du code obtenu par huffman et l'arithmétique, on aura alors :

> CODE MATLAB

```
if(length(enco_huff)<length(enco_arth))
    display("le codage de huffman est le meilleur")
else
    display("le codage arithmetique est le meilleur")
end</pre>
```

> Résultats

```
"le codage de huffman est le meilleur"
```

Et si on peut aussi calculer facilement cette différence qui est de 3.

Remarque:

On a trouvé que la compression de **Huffman est la meilleure** car on travaille avec nombre petit de symboles dans le message (10 symboles), pour le cas d'un **nombre important de symboles** (+200 symboles) la méthode **arithmétique sera la meilleure**.

Partie 2

1. Lecture du fichier texte:

CODE MATLAB

```
%lecture du fichier
TP=importdata('tp.txt');
%transformation de la chaine de caracteres en un vecteur de char
symboles = char(TP);
```

J'ai utilisé le texte du TP1, et j'ai supprimé tous les points, les virgules les caractères accentués, en laissant que les caractères de l'alphabet et les espaces (fichier.txt est en pièce jointe dans le mail). Pour la lecture (éviter tous les erreurs), il faut bien préciser le path du fichier, et puis on va avoir le résultat comme un string qui représente une seule case d'un tableau, pour cela on va la transformer en un vecteur de caractères, on aura alors :

> Résultats

1×1 <u>cell</u> array

['on peut tout te prendre tes biens tes plus belles annees 1 ensemble de tes joies et 1 ensemble de tes merites jusqua ta derniere chemise il te restera toujours tes reves pour rein

La conversion va donner le vecteur « symboles » suivant :

symboles =

TP =

'on peut tout te prendre tes biens tes plus belles annees l ensemble de tes joies et l ensemble de tes merites jusqua ta derniere chemise il te restera toujours tes reves pour reinvent

216

1

2. Calcul de probabilités :

> CODE MATLAB

```
%trouver les nombres d'occurrences pour chaque caractere: on utilise count
%on a considere que a=A ...
nb_a=count(symboles,'a','ignoreCase',true);
nb_b=count(symboles,'b','ignoreCase',true);
nb_c=count(symboles,'c','ignoreCase',true);
nb_d=count(symboles,'d','ignoreCase',true);
nb_e=count(symboles,'e','ignoreCase',true);
nb_f=count(symboles,'f','ignoreCase',true);
nb_g=count(symboles,'g','ignoreCase',true);
nb_h=count(symboles,'h','ignoreCase',true);
nb_i=count(symboles,'i','ignoreCase',true);
nb_j=count(symboles,'j','ignoreCase',true);
```

```
nb k=count(symboles,'k','ignoreCase',true);
nb_l=count(symboles,'l','ignoreCase',true);
nb m=count(symboles,'m','ignoreCase',true);
nb n=count(symboles,'n','ignoreCase',true);
nb o=count(symboles,'o','ignoreCase',true);
nb p=count(symboles, 'p', 'ignoreCase', true);
nb_q=count(symboles, 'q', 'ignoreCase', true);
nb r=count(symboles,'r','ignoreCase',true);
nb s=count(symboles,'s','ignoreCase',true);
nb_t=count(symboles,'t','ignoreCase',true);
nb_u=count(symboles,'u','ignoreCase',true);
nb v=count(symboles,'v','ignoreCase',true);
nb w=count(symboles,'w','ignoreCase',true);
nb_x=count(symboles,'x','ignoreCase',true);
nb_y=count(symboles,'y','ignoreCase',true);
nb z=count(symboles,'z','ignoreCase',true);
nb_points=count(symboles,'.','ignoreCase',true);
nb ver=count(symboles,',','ignoreCase',true);
nb semicol=count(symboles,';','ignoreCase',true);
%pour les espaces on va utiliser la fonction : isstrprop(TEXT, type)
nb spaces=0;
B = isstrprop(symboles, 'wspace');
for i=1:length(B)
nb spaces=nb spaces+B(i);
end
nb spaces;
%definition du vecteur de probabilites
P=1/length(symboles)*[nb a nb b nb c nb d nb e nb f nb g nb h nb i nb j nb k
{\tt nb} 1 {\tt nb} m {\tt nb} n {\tt nb} o {\tt nb} p {\tt nb} q {\tt nb} r {\tt nb} s {\tt nb} t {\tt nb} u {\tt nb} v {\tt nb} w {\tt nb} x {\tt nb} y {\tt nb} z
nb spaces ];
```

On aura alors comme résultat :

Résultats

```
P =
 Columns 1 through 18
   0.0231
            0.0185
                   0.0093
                            0.0231
                                   0.1991
                                            0.0046
                                                           0.0046
                                                                      0.0370 0.0139
                                                                                             0.0463
                                                                                                        0.0231
                                                                                                                   0.0602
                                                                                                                           0.0417
                                                                                                                                    0.0185
                                                                                                                                             0.0139
                                                                                                                                                     0.0556
 Columns 19 through 27
   0.0880
           0.0787
                   0.0463
                            0.0093
                                          0
                                                  0
                                                           0
                                                                       0.1852
```

3. Calcul de la probabilité totale :

> CODE MATLAB

```
%calcul de P totale
p_totale=0;
for i=1:length(P)
  p_totale=p_totale+P(i);
end
p_totale;
if (p_totale ~= 1)
    display("error");
else
    display("everything is okey");
end
```

P_totale =

Après avoir faire la sommation, on a obtenu que p_totale = 1 "everything is okey"

1

4. Calcul de l'information propre :

Il nous faut d'abord éliminer les valeurs nulles du vecteur de probabilités puis on calcule l'information propre :

> CODE MATLAB

```
%on doit utiliser un tableau sans valeurs nulles pour qu'on puisse calculer
%l'entropie et l'information , alors on utilise la fonction find avec la
condition P(i) <> 0 et
%on stoque ces valeurs dans un vecteur P_not_null
P_not_null = P(find(P>0));
% calcul de l'information propre:
Info=-log2(P_not_null);
Info;
```

Résultats

```
P_not_null =

Columns 1 through 18

0.0231  0.0185  0.0093  0.0231  0.1991  0.0046  0.0046  0.0370  0.0139  0.0463  0.0231  0.0602  0.0417  0.0185  0.0139  0.0556  0.0880  0.0787

Columns 19 through 21

0.0463  0.0093  0.1852

>>> Info

Info =

Columns 1 through 18

5.4330  5.7549  6.7549  5.4330  2.3286  7.7549  7.7549  4.7549  6.1699  4.4330  5.4330  4.0544  4.5850  5.7549  6.1699  4.1699  3.5070  3.6674

Columns 19 through 21

4.4330  6.7549  2.4330
```

5. Définition du dictionnaire :

On va d'abord convertir le vecteur symboles des caractères alphabétiques en un vecteur de valeurs numériques en se basant sur la table ASCII, puis on calcule les probabilités d'apparence de chaque symbole (qui sont les mêmes que celle de P) et enfin on utilise **huffmandict** pour définir notre dictionnaire :

CODE MATLAB

```
%definir le vecteur de valeur possibles
alphabets=[97 98 99 100 101 102 103 104 105 106 107 108 109 110 111 112 113
114 115 116 117 118 119 120 121 122 32];
%convertir la chaine en code ascii
conv=abs(symboles);
%calcul de probabilite
P_conv=P;
%le codage de chaque symbole
M_code=huffmandict(alphabets, P_conv);
```

On aura alors les résultats suivants :

Résultats

La conversion du message en ASCII va nous donner :

```
Columns 1 through 31
 111 110
             32 112
                         101
                               117
                                     116
                                                  116
                                                        111
                                                              117
                                                                    116
                                                                            32
                                                                                116
                                                                                       101
                                                                                              32
                                                                                                   112
                                                                                                         114
                                                                                                               101
                                                                                                                     110
                                                                                                                            100
                                                                                                                                  114
                                                                                                                                        101
                                                                                                                                                    116
                                                                                                                                                           101
                                                                                                                                                                 115
                                                                                                                                                                                   105
Columns 32 through 62
 110 115
              32
                   116
                         101
                                115
                                            112
                                                  108
                                                        117
                                                              115
                                                                     32
                                                                                 101
                                                                                       108
                                                                                             108
                                                                                                   101
                                                                                                         115
                                                                                                                            110
                                                                                                                                  110
                                                                                                                                        101
                                                                                                                                              101
                                                                                                                                                    115
                                                                                                                                                            32
                                                                                                                                                                 108
                                                                                                                                                                        32
                                                                                                                                                                                   110
                                                                                                                                                                             101
Columns 63 through 93
 101
     109
              98
                   108
                         101
                                 32
                                     100
                                            101
                                                   32
                                                        116
                                                              101
                                                                    115
                                                                            32
                                                                                 106
                                                                                       111
                                                                                             105
                                                                                                   101
                                                                                                         115
                                                                                                                 32
                                                                                                                     101
                                                                                                                            116
                                                                                                                                   32
                                                                                                                                        108
                                                                                                                                               32
                                                                                                                                                    101
                                                                                                                                                           110
                                                                                                                                                                 115
                                                                                                                                                                       101
                                                                                                                                                                             109
                                                                                                                                                                                    QQ
Columns 94 through 124
        32 100
                   101
                                            115
                                                                                 116
                                                                                       101
                                                                                             115
                                                                                                                      115
                                                                                                                            113
 101
                               116
                                     101
                                                              101
                                                                    114
                                                                           105
                                                                                                         106
                                                                                                                                                                       100
                                                                                                                                                                             101
                                                                                                                                                                                   114
Columns 125 through 155
 105 101 114 101
                                      104
                                            101
                                                  109
                                                        105
                                                              115
                                                                    101
                                                                            32
                                                                                 105
                                                                                       108
                                                                                                   116
                                                                                                         101
                                                                                                                 32
                                                                                                                     114
                                                                                                                            101
                                                                                                                                  115
                                                                                                                                        116
                                                                                                                                              101
                                                                                                                                                    114
                                                                                                                                                                             111
                                                                                                                                                                                   117
                                                                                              32
Columns 156 through 186
 111 117 114 115
                          32
                               116
                                     101
                                           115
                                                        114
                                                              101
                                                                    118
                                                                           101
                                                                                 115
                                                                                        32
                                                                                             112
                                                                                                   111
                                                                                                         117
                                                                                                               114
                                                                                                                       32
                                                                                                                            114
                                                                                                                                  101
                                                                                                                                              110
                                                                                                                                                    118
                                                                                                                                                           101
                                                                                                                                                                 110
                                                                                                                                                                             101
                                                                                                                                                                                   114
Columns 187 through 216
                              110
                                                              117
                                                                    101
                                                                                             111
```

Le vecteur probabilités associées sera alors :

```
P_conv =
 Columns 1 through 18
   0.0231
             0.0185
                      0.0093
                                  0.0231
                                            0.1991
                                                                                     0.0370
                                                                                               0.0139
                                                                                                                             0.0231
                                                                                                                                       0.0602
                                                                                                                                                 0.0417
                                                                                                                                                           0.0185
                                                                                                                                                                      0.0139
                                                                                                                                                                                0.0556
                                                                          0.0046
                                                                                                                   0.0463
 Columns 19 through 27
             0.0787
                      0.0463
```

Alors le dictionnaire obtenu sera donc :

97	[0,0,0,0,0,0]
98	[0,1,0,1,0,1]
99	[0,1,0,1,1,0,0]
100	[0,0,0,0,1,1]
101	[1,0]
102	[0,1,0,1,1,0,1,1,0]
103	[0,1,0,1,1,0,1,1,1,1,1,1,1,1]
104	[0,1,0,1,1,0,1,0]
105	[0,1,0,0,1]
106	[0,0,0,0,0,1,0]
107	[0,1,0,1,1,0,1,1,1,1,1,1,1,0]
108	[0,0,0,1,1]
109	[0,0,0,0,1,0]
110	[0,1,1,0]
111	[0,1,0,0,0]
112	[0,1,0,1,0,0]
113	[0,1,0,1,1,1]
114	[0,1,1,1]
115	[0,0,1,0]
116	[0,0,1,1]
117	[0,0,0,1,0]
118	[0,0,0,0,0,1,1]
119	[0,1,0,1,1,0,1,1,1,1,1,1,0]
120	[0,1,0,1,1,0,1,1,1,1,1,0]
121	[0,1,0,1,1,0,1,1,1,1,0]
122	[0,1,0,1,1,0,1,1,1,0]
32	[1,1]

6. Encodage du texte:

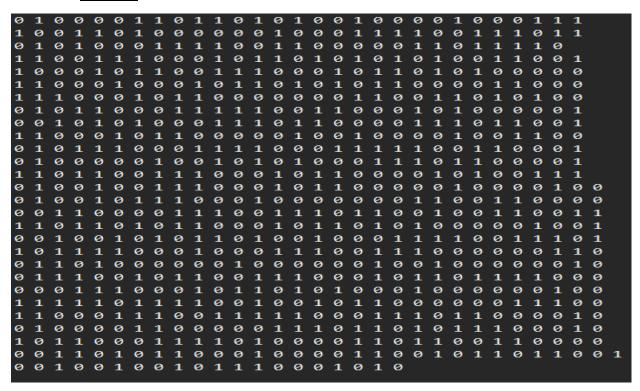
Pour ceci, on va utiliser la fonction **huffmanenco** et puis enregistrer le code obtenu dans un fichier .txt (sera en piece jointe dans le mail) :

> CODE MATLAB

```
%codage du message complet
encodage=huffmanenco(symboles,M_code);
%sauvgarde du resultat dans un fichier .txt
```

Dans l'observation de la taille des fichiers, j'ai remarquée que la taille du texte original est de 1Kb mais la taille du code du texte est de 2Kb, ce qui est illogique car on a fait une compression du texte ce qui veut dire que le code doit être de taille inferieure en mémoire, par analogie a ce qu'on a fait dans la première partie le code contient 817 bits seulement mais si on considère qu'une lettre se code sur 8 bits, le message contient 216 caractères ce qui veut dire qu'il va être codé sur 216*8=1728 bits.

Résultats



7. Décodage avec la fonction huffmandeco:

Dans cette partie on utilise la fonction huffmandeco, on va obtenir un vecteur contenant des valeurs numériques qu'on va convertir en alphabets pour restituer notre message original.

> CODE MATLAB

%decodage de la sequence par huffmandeco:
decodage=huffmandeco(encodage, M_code);
%conversion du code numerique vers ascii
decod ascci=char(decodage);

Résultats

le résultat du décodage en numérique :

```
Columns 1 through 29
111 110
               32
                    112
                           101
                                 117
                                                32
                                                     116
                                                            111
                                                                  117
                                                                         116
                                                                                 32
                                                                                      116
                                                                                             101
                                                                                                    32
                                                                                                          112
                                                                                                                 114
                                                                                                                       101
                                                                                                                              110
                                                                                                                                    100
                                                                                                                                           114
                                                                                                                                                  101
                                                                                                                                                         32
                                                                                                                                                               116
                                                                                                                                                                     101
                                                                                                                                                                            115
Columns 30 through 58
105
      101
             110
                    115
                            32
                                 116
                                        101
                                              115
                                                      32
                                                            112
                                                                  108
                                                                         117
                                                                                115
                                                                                       32
                                                                                              98
                                                                                                   101
                                                                                                          108
                                                                                                                 108
                                                                                                                       101
                                                                                                                              115
                                                                                                                                      32
                                                                                                                                                  110
                                                                                                                                                        110
                                                                                                                                                               101
                                                                                                                                                                     101
                                                                                                                                                                            115
                                                                                                                                                                                    32
                                                                                                                                                                                         108
Columns 59 through 87
       101
  32
             110
                    115
                           101
                                 109
                                         98
                                              108
                                                     101
                                                             32
                                                                  100
                                                                         101
                                                                                 32
                                                                                      116
                                                                                             101
                                                                                                   115
                                                                                                           32
                                                                                                                 106
                                                                                                                       111
                                                                                                                              105
                                                                                                                                    101
                                                                                                                                           115
                                                                                                                                                   32
                                                                                                                                                        101
                                                                                                                                                               116
                                                                                                                                                                       32
                                                                                                                                                                            108
                                                                                                                                                                                    32
Columns 88 through 116
       115
                                                                                                                                     101
110
             101
                    109
                                  108
                                        101
                                                32
                                                     100
                                                            101
                                                                    32
                                                                                101
                                                                                      115
                                                                                              32
                                                                                                   109
                                                                                                          101
                                                                                                                        105
                                                                                                                                           115
                                                                                                                                                   32
                                                                                                                                                        106
                                                                                                                                                               117
                                                                                                                                                                      115
                                                                                                                                                                            113
                                                                         116
                                                                                                                 114
                                                                                                                              116
Columns 117 through 145
       116
Columns 146 through 174
       116
Columns 175 through 203
       114
              101
                    105
                           110
                                 118
                                        101
                                              110
                                                     116
                                                            101
                                                                  114
                                                                                108
                                                                                      101
                                                                                              32
                                                                                                   109
                                                                                                          111
                                                                                                                110
                                                                                                                       100
                                                                                                                              101
                                                                                                                                           113
                                                                                                                                                  117
                                                                                                                                                        101
                                                                                                                                                                     108
                                                                                                                                                                                   111
```

La conversion suivant ASCII:

```
decod ascci =
```

'on peut tout te prendre tes biens tes plus belles annees l'ensemble de tes joies et l'ensemble de tes merites jusqua ta derniere chemise il te restera toujours tes reves pour

On remarque bien que c'est bien le message original qu'on a compressé et puis décompressé.

8. Calcul de l'entropie :

> CODE MATLAB

9. Calcul de la longueur moyenne :

On doit d'abord savoir le nombre de bits pour chaque symbole cad L_i et puis multiplier chaque L_i par son P_i du vecteur de probabilités. Puis, on compare la longueur moyenne par h et on affiche le message d'aucune erreur dans le cas ou h est inferieure a la longueur.

3.7232

CODE MATLAB

```
%calcul de la longueur moyenne:
%on va d'abords savoir le nombre de bits pour chaque symbole:
for i=1:length(M code)
longueur par symbole(i) = length(M code{i,2});
end
longueur par symbole;
longueur=0;
for i=1:length(M code)
    longueur=longueur+P(i)*longueur par symbole(i);
if(h>longueur)
    display("error");
else
    display("it is okey");
end
      Résultats
                                         "it is okey"
On obtient alors:
                                     >> longueur
                                     longueur =
```

10. Calcul de l'efficacité et la redondance :

> CODE MATLAB

%calcul d'efficacite et redondance du code:
%on a efficacite= H/longueur moyenne * 100
%on redondance= 1-efficatcite:

eff=h/longueur *100;
red=100-eff;

Résultats

>> eff

eff =

98.4357

>> red

red =

1.5643

11. Le taux et le gain de compression :

> CODE MATLAB

%calcul du taux de compression:
taille_apres_compression=length(encodage);
%on considere qu'on code un symbole sur 8 bits
taille_avant_compression=length(symboles)*8;
Tc=taille_apres_compression/taille_avant_compression * 100;
%calcul du gain de compression:
Gain=100-Tc;

On aura alors les résultats :

> Résultats

>> TC

Tc =

47.2801

>> Gain

Gain =

52.7199